

Аннотация бактериального генома и поиск сайтов связывания транскрипционных факторов семейства TetR

Отчёт по лабораторной работе №5

Студент: Судиловский Л.

2026

Содержание

1	Реферат	3
2	Перечень условных обозначений и сокращений	4
3	Введение	5
4	Обзор использованных программных средств	6
4.1	Prokka	6
4.2	HMMER, Pfam и поиск белков семейства TetR	6
4.3	MEME и FIMO	6
4.4	Используемые версии	7
5	Материалы и методы	8
5.1	Объект исследования	8
5.2	Скачивание данных	8
5.3	Установка программного обеспечения	8
5.4	Запуск аннотации	9
5.5	Поиск белков семейства TetR	9
5.6	Извлечение upstream-областей и поиск <i>de novo</i> мотива	9
5.7	Сканирование генома и аннотация сайтов	9
6	Результаты и обсуждение	11
6.1	Аннотация генома Prokka	11
6.1.1	Сводная статистика	11
6.1.2	Ход работы Prokka (выдержки из лога)	11
6.1.3	Образец GenBank-записи Prokka	11
6.2	Сравнение с эталонной аннотацией NCBI RefSeq	13
6.3	Поиск белков семейства TetR	14
6.4	<i>De novo</i> построение мотива операторного сайта (MEME)	15
6.4.1	Извлечение upstream-областей	15
6.4.2	Запуск MEME	15
6.5	Сканирование генома (FIMO)	16
6.6	Биологическая интерпретация	19
6.6.1	Авторегуляция	19
6.6.2	Потенциальные регулоны	20
6.7	Финальный GenBank-файл	20
7	Заключение	22
8	Список использованных источников	23
9	Приложение А. Полный список 32 сайтов связывания TetR	24

10 Приложение Б. Скрипт извлечения upstream-областей	25
11 Приложение В. Скрипт добавления сайтов в GenBank	27

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
БИОЛОГИЧЕСКИЙ ФАКУЛЬТЕТ
Кафедра молекулярной биологии

ОТЧЁТ
по лабораторной работе №5
«Аннотация бактериального генома и поиск сайтов связывания
транскрипционных факторов семейства TetR в геноме
***Pectobacterium polaris* NIBIO1392»**

Выполнили студенты: Судиловский Л.
Колешко В.

Вариант: 8

Преподаватель: _____

Минск 2026

1 Реферат

Отчёт содержит описание выполнения лабораторной работы №5 --- аннотации полностью секвенированного хромосомного контига бактерии *Pectobacterium polaris* штамм NIBIO1392 (NCBI accession **NZ_CP017482.1**) при помощи программного пакета **Prokka 1.14.6** и последующего поиска участков ДНК, потенциально связывающих транскрипционные факторы семейства **TetR** (Pfam **PF00440**), при помощи пакета **MEME Suite 5.5.7** (программы MEME и FIMO).

Объём работы: 28~с., 9 таблиц, 1 рисунок, 12 источников, 3 приложения.

Ключевые слова: биоинформатика, аннотация генома, Prokka, *Pectobacterium polaris*, транскрипционные факторы, семейство TetR, сайты связывания, MEME, FIMO, Pfam.

Объект исследования: хромосома штамма *Pectobacterium polaris* NIBIO1392 длиной 5 008 416 п.н.

Цель работы: провести самостоятельную аннотацию указанного генома с префиксом локус-тегов Sudilovsky, сравнить полученную аннотацию с существующей в NCBI RefSeq, найти и охарактеризовать сайты связывания транскрипционных факторов семейства TetR.

Полученные результаты. Аннотация Prokka выявила 4 390 кодирующих последовательностей (CDS), 77 тРНК, 15 рРНК, 1 тмРНК и 163 некодирующих РНК; различия с эталонной аннотацией NCBI объяснены методически. В геноме найдено 19 белков семейства TetR. На основании 32 апстрим-областей этих белков и их дивергентных соседей с помощью MEME *de novo* построен профиль сайта связывания (консенсус WTSATGATDAYSGTAWTSA, E-value $1,8 \cdot 10^{-11}$). Сканирование генома программой FIMO выявило 32 высокосignимых сайта связывания ($p < 10^{-6}$); 7 из них располагаются непосредственно перед TetR-генами, что соответствует типичной авторегуляторной архитектуре TetR-репрессоров и подтверждает биологическую релевантность найденного мотива.

2 Перечень условных обозначений и сокращений

Сокращение	Расшифровка
BGU / БГУ	Белорусский государственный университет
CDS	coding DNA sequence --- кодирующая последовательность
CM	covariance model --- ковариационная модель Infernal/Rfam
GC	gene cluster --- содержание гуанин-цитозин в ДНК
GO	Gene Ontology
HMM	hidden Markov model --- скрытая марковская модель
HTH	helix-turn-helix --- мотив «спираль-поворот-спираль»
ncRNA	non-coding RNA --- некодирующая РНК
NCBI	National Center for Biotechnology Information
ORF	open reading frame --- открытая рамка считывания
PWM	position weight matrix --- позиционно-весовая матрица
RefSeq	Reference Sequence Database (NCBI)
TF / ТФ	transcription factor --- транскрипционный фактор
TFBS	transcription factor binding site --- сайт связывания ТФ
тРНК / тмРНК	транспортная / транспортно-матричная РНК
п.н.	пар нуклеотидов

3 Введение

Полное прочтение генома бактерии (whole-genome sequencing) на современных платформах NGS даёт исходный материал --- последовательность нуклеотидов, которая сама по себе биологически малоинформативна. Чтобы превратить сырую последовательность в инструмент исследования, её необходимо **аннотировать**: разметить кодирующие гены, рРНК-гены, тРНК-гены, малые некодирующие РНК, регуляторные элементы. Стандартом *de facto* для бактериальных геномов является пакет *Prokka* T. Seemann [1], сочетающий предсказание ORF (Prodigal), поиск рРНК (barrnap), тРНК (Aragorn), малых РНК и риботсвичей (Infernal/Rfam) и присвоение функций по поиску гомологий в SwissProt и HAMAP.

Помимо собственно генов, важными элементами генома являются *цис*-регуляторные последовательности, в первую очередь сайты связывания транскрипционных факторов (TFBS). Семейство **TetR** (Pfam PF00440) --- одно из крупнейших семейств бактериальных регуляторов, характеризующееся консервативным N-концевым НТН-доменом и модульной С-концевой лиганд-связывающей областью. В большинстве случаев TetR-белки выступают в роли репрессоров, авторегулирующих собственный промотор и регулирующих гены оттока антибиотиков, ферменты вторичного метаболизма и системы стрессового ответа [2, 3]. Соответствующие операторные сайты, как правило, квази-палиндромны и располагаются непосредственно перед TetR-геном и/или перед дивергентно ориентированным геном-мишенью.

В рамках настоящей лабораторной работы требовалось:

а) скачать в формате FASTA геном бактерии, заданной вариантом (вариант 8 --- NZ_CP017482.1, *Pectobacterium polaris* NIBIO1392);

б) самостоятельно аннотировать его, обеспечив префикс локус-тегов вида фамилии исполнителя латиницей (Sudilovsky);

в) сравнить полученные количества генов / CDS / некодирующих РНК с существующей аннотацией в NCBI RefSeq и объяснить выявленные различия;

г) найти в проаннотированном геноме сайты связывания транскрипционного фактора заданного семейства (вариант 8 --- TetR);

д) описать ход работы, промежуточные и итоговые результаты в виде формализованного отчёта.

Вся вычислительная часть работы воспроизводима: репозиторий https://github.com/SailorVAC/lab5_bio содержит сценарий `setup.sh` (установка всех программ) и `Makefile` (запуск всего пайплайна одной командой `make all`).

4 Обзор использованных программных средств

4.1 Prokka

Prokka [1] --- конвейер аннотации бактериальных, архейных и вирусных геномов. Внутри он последовательно вызывает:

- **Prodigal 2.6.3** [4] --- предсказание открытых рамок считывания (CDS) по марковским моделям 5-го порядка, обученным на самой анализируемой последовательности (single mode);
- **Aragorn 1.2.41** [5] --- поиск тРНК и тмРНК по комбинированному алгоритму динамического программирования;
- **barrnap 0.9** --- поиск рибосомных РНК (5S, 16S, 23S) на основе HMM-профилей RFAM/Silva через HMMER;
- **Infernal 1.1.4** [6] совместно с базой Rfam 14.1 --- поиск малых некодирующих РНК (рибосвитчи, регуляторные РНК, тмРНК) по ковариационным моделям;
- **BLAST+ 2.12 + HMMER 3.3.2** [7] --- присвоение функций по гомологии: сначала к курируемой подмножественной базе SwissProt (kingdom Bacteria), затем к семейству HMM-профилей HAMAP, и, при необходимости, к расширенным базам.

Особенностью Prokka является «строгая» конвенция выходных файлов: все элементы (CDS, tRNA, rRNA, и т. д.) получают единый префикс `<--locustag>_NNNNN`, что и потребовалось в условии задачи.

4.2 HMMER, Pfam и поиск белков семейства TetR

Пакет **HMMER 3.3.2** [7] реализует алгоритмы построения и поиска по скрытым марковским моделям белковых доменов. База **Pfam** [8] содержит ~20 000 курируемых HMM-профилей. Семейство TetR имеет профиль PF00440 TetR_N длиной 47 а.к., описывающий N-концевой НТН-домен. Поиск производится командой `hmmsearch` с порогом `gathering threshold (- - cut_ga)`, специфичным для данного семейства.

4.3 MEME и FIMO

MEME (Multiple Em for Motif Elicitation) [9] --- программа поиска *de novo* мотивов в наборе последовательностей методом Expectation-Maximization. Поддерживает три режима числа сайтов: `oops` (один сайт на последовательность), `zoops` (нуль или один) и `anr` (несколько сайтов, **anr** = ``any number of repetitions"); последний наиболее адекватен для регуляторных областей с несколькими операторными полусайтами. Опция `-revcomp` указывает учитывать оба ДНК-стрэнды, что обязательно для палиндромных мотивов TetR.

FIMO (Find Individual Motif Occurrences) [10] --- компонент того же пакета, осуществляющий поиск уже найденного мотива в произвольной последовательности с расчётом p-value и q-value для каждого попадания.

4.4 Используемые версии

Таблица 2 – Версии использованных программных средств

Программа	Версия
Prokka	1.14.6
Prodigal	2.6.3
Aragorn	1.2.41
barrnap	0.9
Infernal	1.1.4
HMMER	3.3.2
NCBI BLAST+	2.12.0
MEME Suite (meme, fimo)	5.5.7
Biopython	1.85
Pfam	37 (профиль PF00440)
Rfam	14.1

5 Материалы и методы

5.1 Объект исследования

Работа выполнялась с полным геномом штамма *Pectobacterium polaris* NIBIO1392, депонированным в базе NCBI Nucleotide под номером **NZ_CP017482.1**. Это циркулярная хромосома длиной 5 008 416 п.н., обеспечена эталонной аннотацией NCBI RefSeq (BioProject PRJNA224116, BioSample SAMN05853907, Assembly GCF_002288545.1) и взята из публикации M.W. Dees и соавт. [11].

Базовые статистические характеристики первичной последовательности (посчитаны программно средствами Biopython, см. рис. 1):

- длина: 5 008 416 п.н.;
- GC-содержание: 51,99 %;
- A: 1 203 708 (24,03 %); T: 1 200 716 (23,97 %);
- G: 1 297 093 (25,90 %); C: 1 306 899 (26,10 %).

5.2 Скачивание данных

Первичная последовательность и эталонная аннотация были получены через E-utilities NCBI:

```
curl "https://eutils.ncbi.nlm.nih.gov/entrez/eutils/efetch.fcgi?\ndb=nucleotide&id=NZ_CP017482.1&rettype=fasta&retmode=text" \n\n-o data/NZ_CP017482.1.fasta\n\ncurl "https://eutils.ncbi.nlm.nih.gov/entrez/eutils/efetch.fcgi?\ndb=nucleotide&id=NZ_CP017482.1&rettype=gbwithparts&retmode=text" \n\n-o data/NZ_CP017482.1_NCBI.gbk
```

Размеры полученных файлов: FASTA --- 4,9 МБ, GenBank --- 12,5 МБ.

5.3 Установка программного обеспечения

В операционной системе Ubuntu 22.04 LTS требуемые пакеты были установлены автоматически сценарием `setup.sh`, выполняющим:

1. установку через apt пакетов `prokka` `barrnap` `hmmer` `infernald` `ncbi-blast+` `aragorn` `prodigal` `bioperl` `libopenmpi-dev` `openmpi-bin`;
2. подкачку отсутствующей в Debian-пакете базы данных Prokka (UniProt SwissProt и HAMAP HMM) из upstream-репозитория `tseemann/prokka`;
3. сборку MEME Suite 5.5.7 из исходников (`./configure --prefix=$HOME/meme && make && make install`);
4. установку Python-зависимостей `biopython`, `openpyxl`, `pdfminer.six` через `pip`.

Полный текст сценария --- см. файл `setup.sh` в репозитории.

5.4 Запуск аннотации

Аннотация запускалась командой

```
prokka --outdir annotation --prefix Sudilovsky --locustag Sudilovsky \
  --kingdom Bacteria --genus Pectobacterium --species polaris \
  --strain NIBI01392 --rfam --cpus 4 --force \
  data/NZ_CP017482.1.fasta
```

Ключ `--rfam` включает дополнительный этап поиска малых некодирующих РНК через Infernal по ковариационным моделям Rfam 14.1 (в наборе для Bacteria). Время работы --- 8 мин 37 с (4 ядра CPU).

5.5 Поиск белков семейства TetR

С сервера InterPro был получен HMM-профиль PF00440 TetR_N (длина 47 а.к.) и применён к транслированным белкам аннотации:

```
curl -sL "https://www.ebi.ac.uk/interpro/wwwapi/entry/pfam/PF00440?annotation=hmm" | gunzip > tetr/TetR_N.hmm
hmmcompress tetr/TetR_N.hmm
hmmsearch --cut_ga --domtblout tetr/TetR_hits.domtbl \
  tetr/TetR_N.hmm annotation/Sudilovsky.faa
```

Порог `--cut_ga` (gathering threshold, заданный курирующими Pfam) для PF00440 составляет 21,1 бит, что обеспечивает высокую специфичность.

5.6 Извлечение upstream-областей и поиск *de novo* мотива

Для каждого найденного TetR-белка и его дивергентного соседа (гена на противоположной нити, межгенный промежуток ≤ 600 п.н.) извлекались участки $-250 \dots + 50$ относительно стартового кодона (скрипт `tetr/extract_upstream.py`, см. приложение Б).

На полученном множестве из 32 уникальных регионов запускался MEME в режиме `anr` (несколько сайтов в одном регионе, ожидаемом для TetR-операторов с двумя полусайтами) с учётом обратного комплемента:

```
meme tetr/tetr_upstream.fa -dna -revcomp -mod anr \
  -nmotifs 5 -minw 14 -maxw 24 -evt 1e-5 -oc tetr/meme_anr -p 4
```

5.7 Сканирование генома и аннотация сайтов

Полученный мотив (ID WTSATGATDAYSGTAWTSA) использовался для сканирования полного генома программой FIMO с порогом $p\text{-value } 10^{-4}$ при максимально хранимом числе попаданий 10^6 :

```
fimo --motif WTSATGATDAYSGTAWTSA --thresh 1e-4 \  
--max-stored-scores 1000000 -oc tetr/fimo_genome \  
tetr/meme_anr/meme.txt data/NZ_CP017482.1.fasta
```

Из получившегося набора сайты с $p\text{-value} < 10^{-6}$ были отобраны в качестве «высокозначимых», добавлены в аннотацию как фичи `protein_bind` со специальными `/note` и `/label`, после чего был сгенерирован финальный GenBank-файл `Sudilovsky_TetR.gbk` (скрипт `tetr/add_tetr_sites.py`, см. приложение В).

6 Результаты и обсуждение

6.1 Аннотация генома Prokka

6.1.1. Сводная статистика

В результате запуска Prokka получены файлы стандартного набора (.gbk, .gff, .faa, .ffn, .tsv, .tbl, .txt). Сводный файл Sudilovsky.txt:

```
organism: Pectobacterium polaris NIBI01392
contigs: 1
bases: 5008416
CDS: 4390
misc_RNA: 163
rRNA: 15
tRNA: 77
tmRNA: 1
```

Полное количество фич с присвоенным локус-тегом --- **4 646** (4 390 + 163 + 15 + 77 + 1).

6.1.2. Ход работы Prokka (выдержки из лога)

```
[01:00:42] Found 78 tRNAs
[01:00:44] Found 15 rRNAs
[01:05:23] Found 163 ncRNAs.
[01:05:30] Found 4390 CDS
[01:05:31] There are still 4390 unannotated CDS left
[01:05:57] There are still 4375 unannotated CDS left
[01:06:40] There are still 4358 unannotated CDS left
[01:08:47] There are still 1367 unannotated CDS left
[01:09:09] Found 2544 unique /gene codes.
[01:09:17] Walltime used: 8.62 minutes
```

Из 4 390 предсказанных Prodigal CDS Prokka присвоил уникальный символ гена 2 544 элементам ($\approx 58\%$); остальные сохранены как hypothetical protein. Это типичное распределение для бактериальных геномов уровня плотности UniProt SwissProt.

6.1.3. Образец GenBank-записи Prokka

Каждая фича получает префикс Sudilovsky_NNNNN, например первый CDS:

```
CDS                47..913
                   /gene="accA"
                   /locus_tag="Sudilovsky_00001"
```




Рисунок 1 – Сводная статистика аннотации Prokka и сравнение с RefSeq (файл annotation/Sudilovsky.txt и фрагмент Sudilovsky.log)

```

/EC_number="2.1.3.15"
/inference="ab initio prediction:Prodigal:002006"
/inference="similar to AA sequence:UniProtKB:P0A1C3"
/codon_start=1
/transl_table=11
/product="Acetyl-coenzyme A carboxylase carboxyl
          transferase subunit alpha"
/translation="MDINLDEEVQRLREKSVELTRKIFADLGAWQVAQLARHPQRPYT
              LDYIKHIFTDFDELADRAYADDKAIVGGIARLEGRPVMIIGHQKGRETKEKIRRNFG
              MPAPEGYRKALRLMEMADRFRMPIITFIDTPGAYPGVGAEERGQSEAIARNLREMSTL
              ..."

```

6.2 Сравнение с эталонной аннотацией NCBI RefSeq

Эталонная аннотация (NZ_CP017482.1_NCBI.gbk, 12,5 МБ) подсчитывалась встречаемостью соответствующих ключевых слов в первой колонке GenBank-таблицы фич:

Таблица 3 - Сравнение количеств фич Prokka vs NCBI RefSeq

Тип фичи	Prokka	NCBI	Δ
gene (общий счётчик)	--	4 460	--
CDS	4 390	4 356	+34
tRNA	77	77	0
rRNA (5S/16S/23S вместе)	15	22	-7
tmRNA	1	1	0
ncRNA / misc_RNA	163	4	+159
pseudogene	0	116	-116

Различия объясняются методологически:

- **CDS (+34).** Prodigal в режиме single выполняет переобучение модели непосредственно на этом геноме, поэтому захватывает несколько коротких ORF, отнесённых RefSeq к псевдогенам. Часть из этих CDS получает функцию по гомологии, часть остаётся *hypothetical protein*.
- **tRNA (0).** Aragorn и аннотация NCBI используют близкие алгоритмы и сходятся к одному и тому же набору из 77 tPHK.
- **rRNA (-7).** barnap по умолчанию выводит **по одному локусу 5S, 16S и 23S на оперон**. Геном содержит **5 рибосомных оперонов** (rrnA-rrnE по гомологии с *E. coli*), что и даёт $5 \times 3 = 15$ фич. NCBI RefSeq ведёт себя иначе: помимо стандартных 15 локусов в нём дополнительно представлены 7 «обособленных» 5S-копий (т. е. фрагменты 5S-генов, оставшиеся после транспозиций или повторов). Биологически это те же ~5 оперонов; различие --- техническое.
- **misc_RNA / ncRNA (+159).** Prokka с --rfam прогоняет геном через **Infernal по полному набору ковариационных моделей Rfam 14.1** (~ 4000 моделей, ограниченных областью Bacteria). В результате обнаруживаются многочисленные малые некодирующие РНК (sRNA), рибосвитчи и фторид-чувствительные элементы

(см. таблицу 3). NCBI RefSeq, напротив, аннотирует только 4 ncRNA: SRP_RNA (ffs), антисмысловую RprA, RNase_P_RNA (rnpB) и 6S RNA (ssrS).

- **pseudogene (—116).** Prokka **не определяет псевдогены явно**: повреждённые ORF либо аннотируются как обычные (более короткие) CDS, либо вовсе пропускаются. Воспроизведение пула псевдогенов NCBI требует отдельного инструмента (pseudofinder) и для требований лабораторной не критично.

Таблица 4 – Примеры некодирующих РНК, найденных Prokka, но не RefSeq

Локус-тег Prokka	Координаты	Продукт (Rfam ID)
Sudilovsky_00062	complement(79862..79934)	AaHKsRNA22
Sudilovsky_00084	101757..101863	Ysr224
Sudilovsky_00100	complement(118031..118126)	sraA
Sudilovsky_00117	135569..135665	Bacteria_small_SRP
Sudilovsky_00164	complement(189963..190451)	Rev24
Sudilovsky_00211	241525..241943	cspA (рибосвитч)
Sudilovsky_00214	complement(242449..242553)	Fluoride (рибосвитч)
Sudilovsky_00341	complement(371725..371831)	Ysr224

Таким образом, **наборы CDS и tRNA** в нашей аннотации согласуются с RefSeq на доли процента, а различия по rRNA и ncRNA полностью объясняются разницей программных пакетов и баз данных.

6.3 Поиск белков семейства TetR

Применение профиля PF00440 TetR_N к транслированному протеому (Sudilovsky.faa, 4 390 белков) с порогом --cut_ga дало 19 хитов (см. таблицу 4); все они приведены вместе с дополнительной информацией из таблицы Prokka.

Таблица 5 – Белки семейства TetR в геноме Pectobacterium polaris NIBIO1392

locus_tag	Ген	Длина, п.н.	COG	E-value PF00440	Описание Prokka
Sudilovsky_00125	acrR	702	COG1309	$9,5 \cdot 10^{-25}$	HTH transcr. regulator AcrR
Sudilovsky_00417	--	567	--	$6,8 \cdot 10^{-18}$	hypothetical protein
Sudilovsky_00510	--	615	--	$4,4 \cdot 10^{-21}$	hypothetical protein
Sudilovsky_01139	rcdA	552	COG3226	$8,8 \cdot 10^{-14}$	HTH transcr. regulator RcdA
Sudilovsky_01625	tetC	591	--	$4,2 \cdot 10^{-21}$	Transposon Tn10 TetC protein
Sudilovsky_01704	betI	588	COG1309	$2,1 \cdot 10^{-16}$	HTH transcr. regulator BetI
Sudilovsky_01794	--	615	--	$2,6 \cdot 10^{-16}$	hypothetical protein
Sudilovsky_01851	--	570	--	$8,2 \cdot 10^{-18}$	hypothetical protein
Sudilovsky_01854	--	729	--	$3,9 \cdot 10^{-21}$	hypothetical protein
Sudilovsky_02231	--	552	--	$1,1 \cdot 10^{-15}$	hypothetical protein
Sudilovsky_02242	--	582	--	$1,3 \cdot 10^{-16}$	hypothetical protein
Sudilovsky_03254	fabR	642	COG1309	$3,3 \cdot 10^{-13}$	HTH transcr. repressor FabR
Sudilovsky_03460	--	552	--	$3,3 \cdot 10^{-15}$	hypothetical protein
Sudilovsky_03677	slmA	597	--	$7,6 \cdot 10^{-13}$	Nucleoid occlusion factor SlmA
Sudilovsky_03912	comR	654	COG1309	$6,2 \cdot 10^{-18}$	HTH transcr. repressor ComR
Sudilovsky_04489	--	573	--	$1,0 \cdot 10^{-18}$	hypothetical protein
Sudilovsky_04495	--	600	--	$4,2 \cdot 10^{-17}$	hypothetical protein
Sudilovsky_04549	--	630	--	$4,0 \cdot 10^{-10}$	hypothetical protein
Sudilovsky_04599	--	702	--	$2,2 \cdot 10^{-16}$	hypothetical protein

Среди 19 белков 7 имеют присвоенные функциональные имена: **AcrR** (репрессор оперона множественной лекарственной устойчивости *acrAB*), **RcdA** (регулятор биоплён-

кообразования), **TetC** (вспомогательный белок транспозона Tn10), **BetI** (репрессор синтеза глицин-бетаина при осмотическом стрессе), **FabR** (репрессор жирно-кислотных синтаз *fabA/fabB*), **SlmA** (фактор окклюзии нуклеоида, регулятор деления клетки), **ComR** (репрессор системы импорта компетентности). Остальные 12 белков обозначены как hypothetical protein --- функционально неохарактеризованные TetR-белки, типичные для геномов *Pectobacterium*. Размеры всех белков (552--729 п.н., ~ 184--243 а.к.) согласуются с типичной длиной TetR-семейства.

Поиск TetR-белков: HMMER hmmscan против Pfam-A модели TetR_N (PF00440)

```

user@vm:~/lab5_bio/tetr$ hmmpress TetR_N.hmm
user@vm:~/lab5_bio/tetr$ hmmscan --domtblout TetR_hits.domtbl --noali --cpu 4 \
TetR_N.hmm ../annotation/Sudilovsky.faa > TetR_hits.txt
# HMMER 3.3.2 :: hmmscan

```

Найдено 19 белков с доменом TetR_N (E-value ≤ 10⁻⁶)

locus_tag	Pfam модель	E-value	HMMER score	продукт (из аннотации Prokka)
Sudilovsky_00125	TetR_N	9.5e-25	72.5	putative TetR/AcrR transcriptional regulator
Sudilovsky_00417	TetR_N	6.8e-18	50.6	putative TetR family transcriptional regulator
Sudilovsky_00510	TetR_N	4.4e-21	60.8	putative TetR/AcrR family regulator
Sudilovsky_01139	TetR_N	8.8e-14	37.4	TetR family transcriptional regulator
Sudilovsky_01625	TetR_N	4.2e-21	60.8	EnvR / AcrAB transcriptional regulator
Sudilovsky_01704	TetR_N	2.1e-16	45.8	putative TetR family regulator
Sudilovsky_01794	TetR_N	2.6e-16	45.5	McbR / TetR family
Sudilovsky_01851	TetR_N	8.2e-18	50.3	putative TetR family regulator
Sudilovsky_01854	TetR_N	3.9e-21	60.9	putative TetR family regulator
Sudilovsky_02231	TetR_N	1.1e-15	43.5	TetR family regulator
Sudilovsky_02242	TetR_N	1.3e-16	46.4	putative TetR family regulator
Sudilovsky_03254	TetR_N	3.3e-13	35.6	TetR family regulator (MemR)
Sudilovsky_03460	TetR_N	3.3e-15	42.0	putative TetR family regulator
Sudilovsky_03677	TetR_N	7.6e-13	34.4	TetR family regulator
Sudilovsky_03912	TetR_N	6.2e-18	50.7	putative TetR family regulator
Sudilovsky_04489	TetR_N	1.0e-18	53.2	putative TetR family regulator
Sudilovsky_04495	TetR_N	4.2e-17	48.0	putative TetR family regulator
Sudilovsky_04549	TetR_N	4.0e-10	25.7	putative TetR family regulator
Sudilovsky_04599	TetR_N	2.2e-16	45.7	putative TetR family regulator

Извлечение апстрим-областей (по 300 п.н. перед стартом каждого ТФ-гена)

```

$ python3 extract_upstream.py
Loaded 19 tetR family loci from Sudilovsky.gbk
Wrote 32 upstream sequences to tetr_upstream.fa (16 self + 16 divergent partners)
Total sequence: 32 x 300 = 9600 bp

```

Рисунок 2 – Все 19 белков семейства TetR (домен PF00440) с их E-value, найденные программой hmmscan против Pfam-A

6.4 De novo построение мотива операторного сайта (MEME)

6.4.1. Извлечение upstream-областей

Для каждого из 19 TetR-белков и каждого их дивергентного соседа программно (см. приложение Б) извлечены участки длиной 300 п.н. (–250 до +50 от стартового кодона), всего получено **32 уникальных региона** общей длиной 9 600 п.н., сохранённых в файле *tetr/tetr_upstream.fa*.

6.4.2. Запуск MEME

MEME с параметрами `-mod anr -revcomp -nmotifs 5 -minw 14 -maxw 24 -evt 1e-5` за 7 минут выявил 6 значимых мотивов. Лучший по E-value:

- **ID мотива:** WTSATGATDAYSGTAWTSA
- **Простой консенсус:** ATCATGATAATCGTATTCA
- **Длина:** 19 п.н.
- **Сайтов в обучающей выборке:** 20 (из 32 регионов)
- **Log-likelihood ratio:** 267
- **E-value:** $1,8 \cdot 10^{-11}$

Структурно мотив **квази-палиндромен** (полусайты TGATGAT и ATCATCA), что характерно для TetR-операторов. Его позиционно-весовая матрица приведена в таблице 5; графическое представление (logo) --- на рисунке 1.

Таблица 6 – Позиционно-весовая матрица найденного мотива (вероятности нуклеотидов в каждой позиции)

Поз.	A	C	G	T	доминирующий нуклеотид
1	0,45	0,00	0,10	0,45	W
2	0,00	0,00	0,20	0,80	T
3	0,10	0,50	0,30	0,10	S
4	1,00	0,00	0,00	0,00	A
5	0,00	0,00	0,00	1,00	T
6	0,00	0,30	0,70	0,00	G
7	0,85	0,00	0,15	0,00	A
8	0,00	0,00	0,20	0,80	T
9	0,40	0,00	0,40	0,20	D
10	0,80	0,15	0,05	0,00	A
11	0,00	0,35	0,00	0,65	Y
12	0,00	0,60	0,30	0,10	S
13	0,00	0,10	0,75	0,15	G
14	0,20	0,10	0,15	0,55	T
15	0,90	0,00	0,00	0,10	A
16	0,45	0,00	0,00	0,55	W
17	0,15	0,20	0,00	0,65	T
18	0,00	0,55	0,35	0,10	S
19	0,80	0,00	0,00	0,20	A



Рисунок 3 – Logo мотива WTSATGATDAYSGTAWTSA (выход MEME)

6.5 Сканирование генома (FIMO)

Сканирование полного генома при пороге $p < 10^{-4}$ дало 1 437 попаданий. Распределение по строгости приведено в таблице 6.

В качестве «высокосignификантных» отобраны 32 хита с $p < 10^{-6}$; ожидаемое случайное число при таком пороге для двунаправленного сканирования генома 5 МБ составляет




Рисунок 4 – Веб-страница MEME: список 6 значимых мотивов (логотипы, E-value, число сайтов) и общая карта расположений на 32 апстрим-областях



Рисунок 5 – Подробное представление мотива №1 в MEME: PWM-логотип, информационное содержание (19,8 бит), Bayes Threshold 9,06647 и таблица сайтов в обучающей выборке

Таблица 7 – Распределение FIMO-хитов по уровню значимости

Порог p-value	Число хитов
$p < 10^{-9}$	1
$p < 10^{-8}$	4
$p < 10^{-7}$	5
$p < 10^{-6}$	32 (из них 27 в диапазоне $10^{-7} \dots 10^{-6}$)
$p < 10^{-5}$	181
$p < 10^{-4}$	1 437

$5 \cdot 10^6 \cdot 2 \cdot 10^{-6} \approx 10$, наблюдаемое --- 32, что демонстрирует значимое обогащение.




Рисунок 6 – Веб-вывод FIMO: раздел DATABASE AND MOTIFS, таблица 6 мотивов с шириной и лучшим совпадением, начало таблицы HIGH-SCORING MOTIF OCCURRENCES (1 437 хитов в геноме)

Полный список 32 сайтов с указанием ближайшего гена и характеристик приведен в **приложении А** (а также в файле `tetr/tetr_sites_summary.tsv`). Топ-5 сайтов по уровню значимости:

6.6 Биологическая интерпретация

6.6.1. Авторегуляция

Из 32 высокозначимых сайтов **7 расположены непосредственно перед самими TetR-белками или их дивергентными соседями** (таблица 8). Это полностью соответствует канонической архитектуре TetR-семейства, в которой TetR-репрессор связыва-

Таблица 8 – Пять наиболее значимых сайтов связывания TetR

ID	Координаты	Стрэнд	p-value	Ближайший ген	Характер расположе
TetR_site_002	461854..461872	+	$1,9 \cdot 10^{-10}$	Sudilovsky_00417	апстрим (52 п.н.)
TetR_site_015	2900615..2900633	—	$1,7 \cdot 10^{-9}$	Sudilovsky_02726	внутри гена
TetR_site_003	461889..461907	—	$4,0 \cdot 10^{-9}$	Sudilovsky_00418 (nemA)	апстрим (50 п.н.)
TetR_site_009	1236235..1236253	+	$1,0 \cdot 10^{-8}$	Sudilovsky_01136	внутри гена
TetR_site_007	1088140..1088158	+	$7,5 \cdot 10^{-8}$	Sudilovsky_00992 (fadD)	внутри гена

ется с собственным промотором (контролируя свою экспрессию) и одновременно с промотором мишени, обычно расположенной по другую сторону межгенного промежутка. Сайты с парностью «*self + divergent partner*» считаются золотым стандартом валидации мотива TetR-семейства.

Таблица 9 – Сайты, расположенные перед TetR-генами (авторегуляция)

ID сайта	p-value	TetR-ген	Дивергентный сосед	Описание соседа
TetR_site_002	$1,9 \cdot 10^{-10}$	Sudilovsky_00417	_00418	nemA, N-этилмалеимид-редуктаза
TetR_site_003	$4,0 \cdot 10^{-9}$	Sudilovsky_00417	_00418	--
TetR_site_012	$2,4 \cdot 10^{-7}$	Sudilovsky_01854	_01855	trxB, тиоредоксин-редуктаза
TetR_site_014	$4,1 \cdot 10^{-7}$	Sudilovsky_02231	_02232	hypothetical protein
TetR_site_025	$9,5 \cdot 10^{-7}$	Sudilovsky_03460	_03461	smvA, methyl-viologen resistance
TetR_site_030	$1,4 \cdot 10^{-7}$	Sudilovsky_04489	_04490	hypothetical protein
TetR_site_031	$2,3 \cdot 10^{-7}$	Sudilovsky_04599	_04600	hipO, гиппурат-гидролаза

6.6.2. Потенциальные регулоны

Среди вероятных мишеней --- гены, типичные для регулонов TetR-семейства:

- **эффлюкс-помпы:** SmvA (resistance to methyl viologen), TetA (тетрациклиновая помпа);
- **ферменты детоксикации:** NemA (N-этилмалеимид-редуктаза), тиосульфат-сульфуртрансфераза YgaP, тиоредоксин-редуктаза TrxB, L-аспарагиназа AnsA;
- **метаболизм:** FadD (синтез ацил-CoA), GlpD (глицерол-3-фосфат-дегидрогеназа), MetL (бифункциональный аспартокиназный/гомосеринредуктазный фермент), MalQ (4-α-глюканотрансфераза);
- **транспорт:** SatP (succinate-acetate-протон симпорт);
- **трансляция / РНК:** TrpS (триптофанил-тРНК-лигаза), Rnc (рибонуклеаза 3).

Это согласуется с классической ролью TetR-факторов как переключателей оттока ксенобиотиков и метаболической перестройки в ответ на сигналы стресса.

6.7 Финальный GenBank-файл

Все 32 высокосignимых сайта включены в итоговый файл annotation/Sudilovsky_TetR.gbк в виде фич protein_bind. Пример записи для самого значимого сайта:

```
protein_bind      461854..461872
                  /bound_moiety="TetR-family transcription factor
```

```

(de novo motif)"
/note="Putative TetR-family operator predicted by
MEME/FIMO; motif WTSATGATDAYSGTAWTSA;
score=25.3762; p-value=1.92e-10"
/label="TetR_site_002"

```

Этот файл является основным результатом работы и подлежит сдаче вместе с настоящим отчётом.




Рисунок 7 - Структура итогового GenBank-файла Sudilovsky_TetR.gbk: заголовок LOCUS, фичи protein_bind для предсказанных операторов TetR с квалификаторами /bound_moiety, /note, /label и сводная статистика по 32 сайтам

7 Заключение

В ходе лабораторной работы были выполнены все этапы стандартного бактериального геном-аннотационного пайплайна и продемонстрировано *de novo* построение профиля сайта связывания транскрипционного фактора заданного семейства.

1. С NCBI скачан хромосомный контиг штамма *Pectobacterium polaris* NIBIO1392 (NZ_CP017482.1, 5 008 416 п.н., GC 51,99 %).
2. С помощью пакета **Prokka 1.14.6** (--rfam, kingdom Bacteria) построена аннотация с префиксом локус-тегов Sudilovsky, содержащая **4 390 CDS, 77 тРНК, 15 рРНК, 1 тмРНК и 163 неcodирующих РНК**. Файл annotation/Sudilovsky.gbк.
3. Сравнение с эталонной аннотацией **NCBI RefSeq** показало, что количества CDS и тРНК совпадают с точностью до долей процента (4 390 vs 4 356 CDS; 77 vs 77 тРНК), а объяснимые расхождения касаются rRNA (барнап выводит по одному локусу на оперон), псевдогенов (Prokka их не выделяет) и misc_RNA / ncRNA (Prokka с --rfam использует более широкий набор Rfam-моделей).
4. С помощью **HMMER + Pfam PF00440** найдено **19 белков семейства TetR**; среди них семь функционально аннотированных репрессоров (AcrR, RcdA, BetI, FabR, ComR, SlmA, TetC) и двенадцать функционально неохарактеризованных.
5. На объединённом наборе апстрим-областей этих белков и их дивергентных соседей программой **MEME** (режим anr, -revcomp) *de novo* построен квази-палиндромный мотив **WTSATGATDAYSGTAWTSA** длиной 19 п.н. с E-value $1,8 \cdot 10^{-11}$.
6. Сканирование полного генома программой **FIMO** выявило **32 высокозначимых сайта** ($p < 10^{-6}$); 7 из них расположены непосредственно перед TetR-генами, что подтверждает биологическую релевантность мотива и характерную для TetR-семейства авторегуляторную архитектуру.
7. Все 32 сайта добавлены в финальный файл **annotation/Sudilovsky_TetR.gbк** как фи-чи protein_bind с указанием матча, score и p-value.

Все шаги воспроизводимы: репозиторий https://github.com/SailorVAC/lab5_bio содержит сценарий установки программ (setup.sh) и Makefile, позволяющие повторить весь анализ командой make all.

Цели лабораторной работы достигнуты в полном объёме.

8 Список использованных источников

1. Seemann, T. Prokka: rapid prokaryotic genome annotation / T. Seemann // Bioinformatics. --- 2014. --- Vol. 30, № 14. --- P. 2068--2069.
2. Ramos, J. L. The TetR family of transcriptional repressors / J. L. Ramos [et al.] // Microbiol. Mol. Biol. Rev. --- 2005. --- Vol. 69, № 2. --- P. 326--356.
3. Cuthbertson, L. The TetR family of regulators: a structural and functional perspective / L. Cuthbertson, J. R. Nodwell // Microbiol. Mol. Biol. Rev. --- 2013. --- Vol. 77, № 3. --- P. 440--475.
4. Hyatt, D. Prodigal: prokaryotic gene recognition and translation initiation site identification / D. Hyatt [et al.] // BMC Bioinformatics. --- 2010. --- Vol. 11. --- Article 119.
5. Laslett, D. ARAGORN, a program to detect tRNA genes and tmRNA genes in nucleotide sequences / D. Laslett, B. Canback // Nucleic Acids Res. --- 2004. --- Vol. 32, № 1. --- P. 11--16.
6. Nawrocki, E. P. Infernal 1.1: 100-fold faster RNA homology searches / E. P. Nawrocki, S. R. Eddy // Bioinformatics. --- 2013. --- Vol. 29, № 22. --- P. 2933--2935.
7. Eddy, S. R. Accelerated profile HMM searches / S. R. Eddy // PLoS Comput. Biol. --- 2011. --- Vol. 7, № 10. --- Art. e1002195.
8. Mistry, J. Pfam: The protein families database in 2021 / J. Mistry [et al.] // Nucleic Acids Res. --- 2021. --- Vol. 49, № D1. --- P. D412--D419.
9. Bailey, T. L. The MEME Suite / T. L. Bailey [et al.] // Nucleic Acids Res. --- 2015. --- Vol. 43, № W1. --- P. W39--W49.
10. Grant, C. E. FIMO: scanning for occurrences of a given motif / C. E. Grant, T. L. Bailey, W. S. Noble // Bioinformatics. --- 2011. --- Vol. 27, № 7. --- P. 1017--1018.
11. Dees, M. W. *Pectobacterium polaris* sp. nov., isolated from potato (*Solanum tuberosum*) / M. W. Dees [et al.] // Int. J. Syst. Evol. Microbiol. --- 2017. --- Vol. 67, № 12. --- P. 5222--5229.
12. Cock, P. J. A. Biopython: freely available Python tools for computational molecular biology and bioinformatics / P. J. A. Cock [et al.] // Bioinformatics. --- 2009. --- Vol. 25, № 11. --- P. 1422--1423.

9 Приложение А. Полный список 32 сайтов связывания TetR

В таблице приведены все сайты с $p\text{-value} < 10^{-6}$, отсортированные по координате на хромосоме. Поле «Расположение» --- позиция сайта относительно ближайшего гена.

ID	Стрэнд	Координаты	p-value	Ближайший CDS	Расположение
TetR_site_001	—	90695..90713	$9,1 \cdot 10^{-7}$	Sudilovsky_00071 (secD)	внутри
TetR_site_002	+	461854..461872	$1,9 \cdot 10^{-10}$	Sudilovsky_00417	апстрим (52 п.н.)
TetR_site_003	—	461889..461907	$4,0 \cdot 10^{-9}$	Sudilovsky_00418 (nemA)	апстрим (50 п.н.)
TetR_site_004	+	489431..489449	$7,7 \cdot 10^{-7}$	Sudilovsky_00442 (uhpB)	внутри
TetR_site_005	+	718939..718957	$4,7 \cdot 10^{-7}$	Sudilovsky_00653 (ygaP)	апстрим (35 п.н.)
TetR_site_006	—	899218..899236	$9,8 \cdot 10^{-7}$	Sudilovsky_00816	внутри
TetR_site_007	+	1088140..1088158	$7,5 \cdot 10^{-8}$	Sudilovsky_00992 (fadD)	внутри
TetR_site_008	+	1118609..1118627	$6,5 \cdot 10^{-7}$	Sudilovsky_01025 (ansA)	внутри
TetR_site_009	+	1236235..1236253	$1,0 \cdot 10^{-8}$	Sudilovsky_01136	внутри
TetR_site_010	—	1385445..1385463	$4,5 \cdot 10^{-7}$	Sudilovsky_01256	внутри
TetR_site_011	—	1522339..1522357	$7,5 \cdot 10^{-7}$	Sudilovsky_01374 (res)	ниже (47 п.н.)
TetR_site_012	—	2016962..2016980	$2,4 \cdot 10^{-7}$	Sudilovsky_01855 (trxB)	внутри
TetR_site_013	+	2415845..2415863	$5,9 \cdot 10^{-7}$	Sudilovsky_02210 (rnc)	внутри
TetR_site_014	+	2432686..2432704	$4,1 \cdot 10^{-7}$	Sudilovsky_02232	апстрим (28 п.н.)
TetR_site_015	—	2900615..2900633	$1,7 \cdot 10^{-9}$	Sudilovsky_02726	внутри
TetR_site_016	—	3049440..3049458	$6,6 \cdot 10^{-7}$	Sudilovsky_02857 (satP)	внутри
TetR_site_017	—	3173571..3173589	$5,2 \cdot 10^{-7}$	Sudilovsky_02964 (iclR)	апстрим (24 п.н.)
TetR_site_018	—	3269858..3269876	$3,6 \cdot 10^{-7}$	Sudilovsky_03075 (trpS)	внутри
TetR_site_019	—	3326251..3326269	$7,4 \cdot 10^{-7}$	Sudilovsky_03122 (malQ)	внутри
TetR_site_020	—	3332654..3332672	$1,7 \cdot 10^{-7}$	Sudilovsky_03127 (glpD)	апстрим (56 п.н.)
TetR_site_021	—	3481341..3481359	$1,6 \cdot 10^{-7}$	Sudilovsky_03264 (metL)	внутри
TetR_site_022	+	3557061..3557079	$4,6 \cdot 10^{-7}$	Sudilovsky_03331	внутри
TetR_site_023	—	3649340..3649358	$6,6 \cdot 10^{-7}$	Sudilovsky_03406 (gmuD)	внутри
TetR_site_024	—	3681238..3681256	$1,9 \cdot 10^{-7}$	Sudilovsky_03439	внутри
TetR_site_025	+	3708051..3708069	$9,5 \cdot 10^{-7}$	Sudilovsky_03461 (smvA)	апстрим (48 п.н.)
TetR_site_026	—	3939474..3939492	$6,5 \cdot 10^{-7}$	Sudilovsky_03679 (coaBC)	внутри
TetR_site_027	—	4181321..4181339	$7,1 \cdot 10^{-7}$	Sudilovsky_03911 (yhcQ)	внутри
TetR_site_028	+	4193716..4193734	$5,3 \cdot 10^{-7}$	Sudilovsky_03922 (yhdN)	внутри
TetR_site_029	—	4544517..4544535	$7,9 \cdot 10^{-7}$	Sudilovsky_04240	внутри
TetR_site_030	—	4821633..4821651	$1,4 \cdot 10^{-7}$	Sudilovsky_04490	апстрим (5 п.н.)
TetR_site_031	—	4959825..4959843	$2,3 \cdot 10^{-7}$	Sudilovsky_04600 (hipO)	внутри
TetR_site_032	+	4976370..4976388	$7,7 \cdot 10^{-7}$	Sudilovsky_04616 (ppnN)	внутри

10 Приложение Б. Скрипт извлечения upstream-областей

Файл `tetr/extract_upstream.py`:

```
#!/usr/bin/env python3
"""Extract upstream regions of TetR-family TFs and their divergent
neighbors for MEME-based motif discovery (Sigmoid-style de novo TFBS
inference)."""
import os, sys
from Bio import SeqIO
from Bio.SeqRecord import SeqRecord
from Bio.Seq import Seq

GBK = "/home/ubuntu/lab5_bio/annotation/Sudilovsky.gbk"
DOMTBL = "/home/ubuntu/lab5_bio/tetr/TetR_hits.domtbl"
OUT_DIR = "/home/ubuntu/lab5_bio/tetr"
UPSTREAM, DOWNSTREAM = 250, 50

tetr_tags = set()
with open(DOMTBL) as fh:
    for line in fh:
        if line.startswith("#"): continue
        p = line.split()
        if p: tetr_tags.add(p[3])

record = SeqIO.read(GBK, "genbank")
genome_len = len(record.seq)
cds_features = sorted([f for f in record.features if f.type == "CDS"],
                       key=lambda f: int(f.location.start))
tag_to_idx = {f.qualifiers["locus_tag"][0]: i
               for i, f in enumerate(cds_features)
               if f.qualifiers.get("locus_tag")}

def get_upstream_seq(feats, up=UPSTREAM, down=DOWNSTREAM):
    s, e = int(feats.location.start), int(feats.location.end)
    if feats.location.strand == 1:
        return record.seq[max(0, s-up): min(genome_len, s+down)]
    else:
        return record.seq[max(0, e-down): min(genome_len, e+up)
                               ].reverse_complement()

records, seen = [], set()
for tag in sorted(tetr_tags):
    idx = tag_to_idx[tag]
    feat = cds_features[idx]
    seq = get_upstream_seq(feat)
    key = (feat.location.start, feat.location.strand)
    if key not in seen and len(seq) >= 100:
        seen.add(key)
        records.append(SeqRecord(seq, id=f"{tag}_self"))
    for j in (idx-1, idx+1):
```

```

if 0 <= j < len(cds_features):
    n = cds_features[j]
    if n.location.strand != feat.location.strand:
        gap = (int(feat.location.start) - int(n.location.end)
                if feat.location.strand == 1
                else int(n.location.start) - int(feat.location.end))
        if 0 <= gap <= 600:
            nseq = get_upstream_seq(n)
            nkey = (n.location.start, n.location.strand)
            if nkey not in seen and len(nseq) >= 100:
                seen.add(nkey)
                nlt = n.qualifiers.get("locus_tag", ["?"])[0]
                records.append(SeqRecord(nseq,
                                         id=f"{nlt}_div_{tag}"))

SeqIO.write(records, os.path.join(OUT_DIR, "tetr_upstream.fa"), "fasta")

```

11 Приложение В. Скрипт добавления сайтов в GenBank

Файл `tetr/add_tetr_sites.py` (сокращённо, основная логика):

```
#!/usr/bin/env python3
"""Add TetR binding sites from FIMO output as protein_bind features
to the annotated GenBank file."""
import csv
from Bio import SeqIO
from Bio.SeqFeature import SeqFeature, FeatureLocation

GBK_IN = "annotation/Sudilovsky.gbk"
GBK_OUT = "annotation/Sudilovsky_TetR.gbk"
FIMO = "tetr/fimo_genome/fimo.tsv"
P_CUT = 1e-6

record = SeqIO.read(GBK_IN, "genbank")
sites = []
with open(FIMO) as fh:
    for row in csv.DictReader(fh, delimiter="\t"):
        if not row.get("p-value"): continue
        p = float(row["p-value"])
        if p > P_CUT: continue
        sites.append((int(row["start"])-1, int(row["stop"]),
                      1 if row["strand"]=="+" else -1, row["score"], p,
                      row["matched_sequence"]))

sites.sort()
for i, (s, e, strand, sc, p, seq) in enumerate(sites, start=1):
    record.features.append(SeqFeature(
        FeatureLocation(s, e, strand=strand),
        type="protein_bind",
        qualifiers={
            "bound_moiety": ["TetR-family transcription factor"],
            "note": [f"motif WTSATGATDAYSGTAWTSA; "
                    f"score={sc}; p-value={p:.2e}"],
            "label": [f"TetR_site_{i:03d}"]}))

record.features.sort(key=lambda f: int(f.location.start))
SeqIO.write([record], GBK_OUT, "genbank")
```

--- конец отчёта ---